ARAŞTIRMA SUNUMU

AKROMEGALİ KOHORTUNDA MORTALİTE TAHMİNİ

Keşifsel analiz · Veri kalitesi · Sızıntı kontrolü · Model karşılaştırması

607 hasta · 51 vefat (%8,4) · 5 model girdisi

Dummy referansı, Lojistik Regresyon ve Random Forest

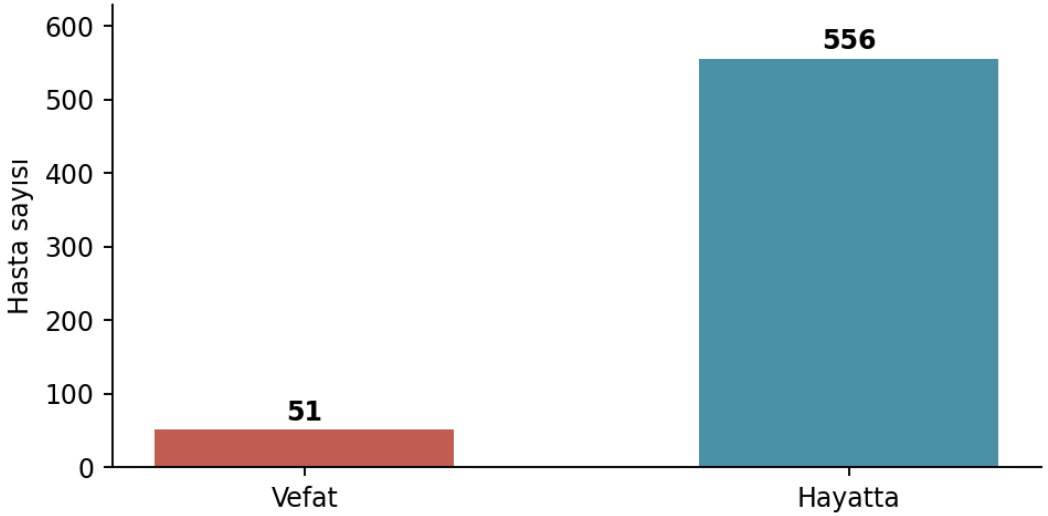
Galatasaray Üniversitesi · Veri Bilimi Uygulamaları · Kasım 2026

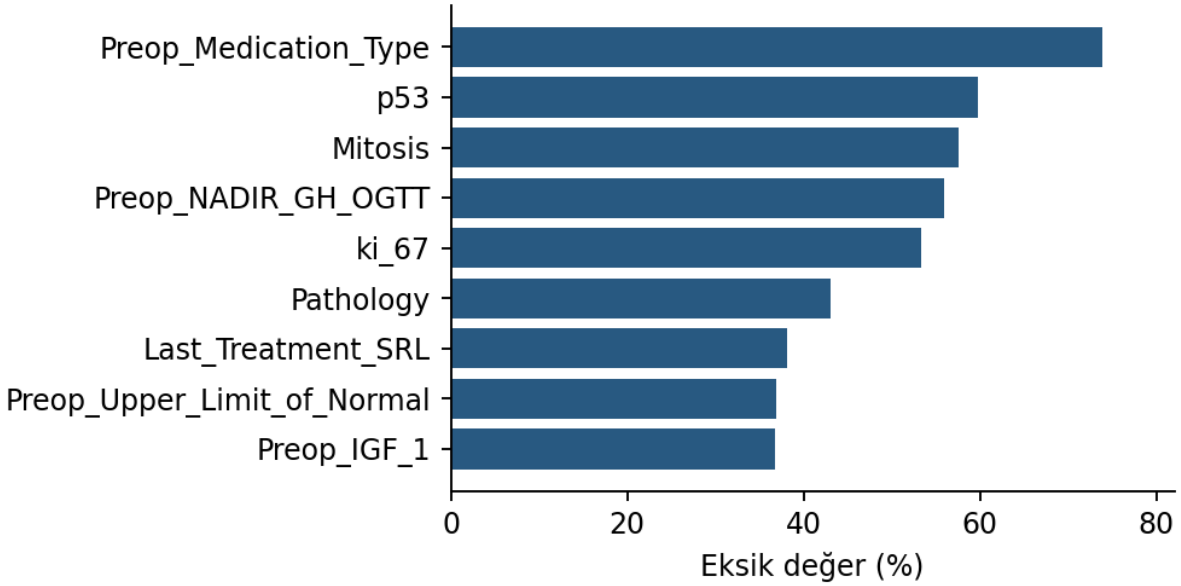
HAZIRLAYANLAR

SELİN ÜNSAL · 25531116

CEREN ZORBOZAN · 25531105

Hedef dağılımı ve eksik değerler

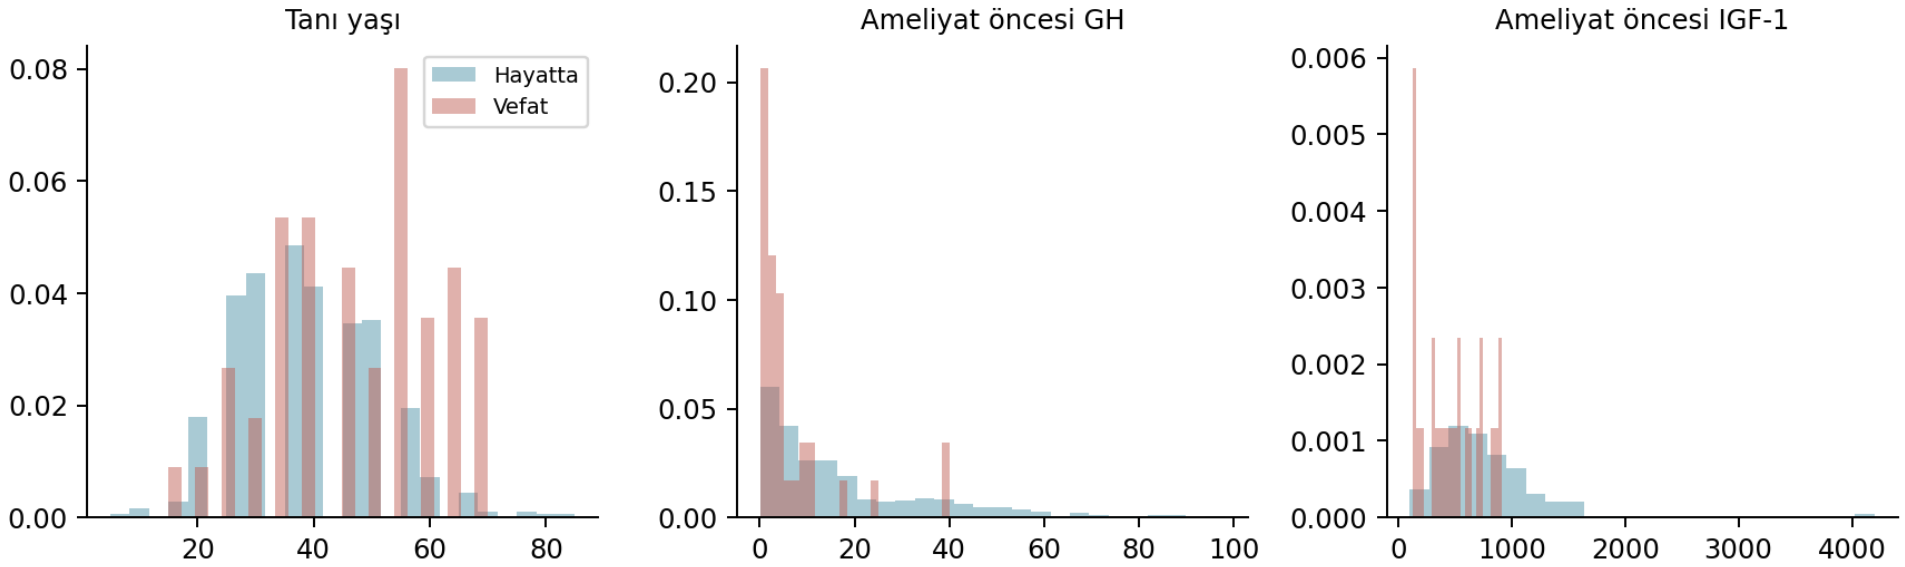




- 556 hasta hayatta, 51 hasta vefat (%8,4). Veri belirgin biçimde dengesiz.
- Çoğunluk sınıfını tahmin eden modelin doğruluğu yaklaşık %91,6; tek başına accuracy yeterli değil.
- Preop_IGF_1 eksikliği: vefat %49,0; hayatta %35,6. Tümör boyutu: %29,4 / %19,4.

```
df["Alive"].value_counts()
df.isna().mean().sort_values(ascending=False).head(10)
df.groupby("Alive")[["Preop_IGF_1", "Preop_Tm_Size_MAX_mm"]].agg(lambda s: s.isna().mean())
```

Sürekli değişkenler hedefe göre



GRUPLARIN MEDYANLARI

- Tanı yaşı: vefat 50, hayatta 35.
- Preop_GH: vefat 3,15; hayatta 11,38.
- Preop_IGF_1: vefat 442,05; hayatta 688,85.
- Tümör boyutu: vefat 15,50 mm; hayatta 15,55 mm.

GH ve IGF-1 dağılımları sağa çarpık (çarpıklık: 1,68 ve 3,34). Gruplar arası farklar nedensellik göstermez.

Veri sözleşmesi: kontrol et ve boz

VERİ SÖZLEŞMESİ

Kural	Kontrol	İhlal
R1	Alive yalnızca 0 veya 1	**0**
R2	Tanı yaşı ≤ ameliyat yaşı ≤ son yaş	**0***
R3	TSS=YOK ⇔ NOT_OPERATED	**0***

```
assert df["Alive"].isin([0, 1]).all()
bad = df.copy()
bad.loc[10, "Alive"] = 2
assert not bad["Alive"].isin([0, 1]).all()
```

* Yaş kuralı 490, ameliyat/remisyon kuralı 581 değerlendirilebilir satırda ihlalsizdir. Boş alanlar için ayrıca kontrol gerekir.

Kaynak veri değiştirilmeden, kopya üzerinde kasıtlı bozulma testi yapıldı; bozuk hedef değeri yakalandı.

Veri sızıntısı: tahmin anında bilinir mi?

MODELDEN ÇIKARILAN DEĞİŞKENLER

Age	Son temas / vefat yaşı olabilir.
Follow_Up_Duration_Month	Tanı anında bilinmeyen takip süresi.
Last_* ve Last_Status	Takip sonundaki durum veya ölçümler.
Postop_* / Remission_3_Month	Ameliyat sonrası sonuçlar.
Age_at_Operation / Number_of_Operations	Tahmin anından sonraki müdahale bilgisi olabilir.

Ana model yalnızca 5 değişken kullanır: tanı yaşı, cinsiyet, ameliyat öncesi GH, IGF-1 ve tümör boyutu.

Sınırlılık: ameliyat öncesi ölçümlerin seçilen tahmin anında gerçekten mevcut olduğu ayrıca doğrulanmalıdır.

Eksik değerleri nasıl işledik?

- Eksik kayıtları topluca silmek, az sayıdaki vefat gözlemini daha da azaltabilir.
- Sayısal değişkenler eğitim katmanında öğrenilen medyanla dolduruldu.
- Eksiklik göstergeleri (add_indicator=True) modele eklendi.
- Lojistik regresyonda sayısal alanlar ölçeklendi; cinsiyet One-Hot kodlandı.

PIPELINE İÇİNDE ÖN İŞLEME

```
num = Pipeline([
  ("imputer", SimpleImputer(strategy="median",
                            add_indicator=True)),
  ("scaler", StandardScaler())
])
model = Pipeline([("preprocessor", preprocessor),
                  ("classifier", LogisticRegression(...))])
```

Pipeline her CV katmanında yalnızca eğitim verisine fit edilir; böylece testten medyan veya ölçekleme bilgisi alınmaz.

Train/test ayrımı ve Dummy referansı

485 eğitim hastası

41 vefat

122 test hastası

10 vefat

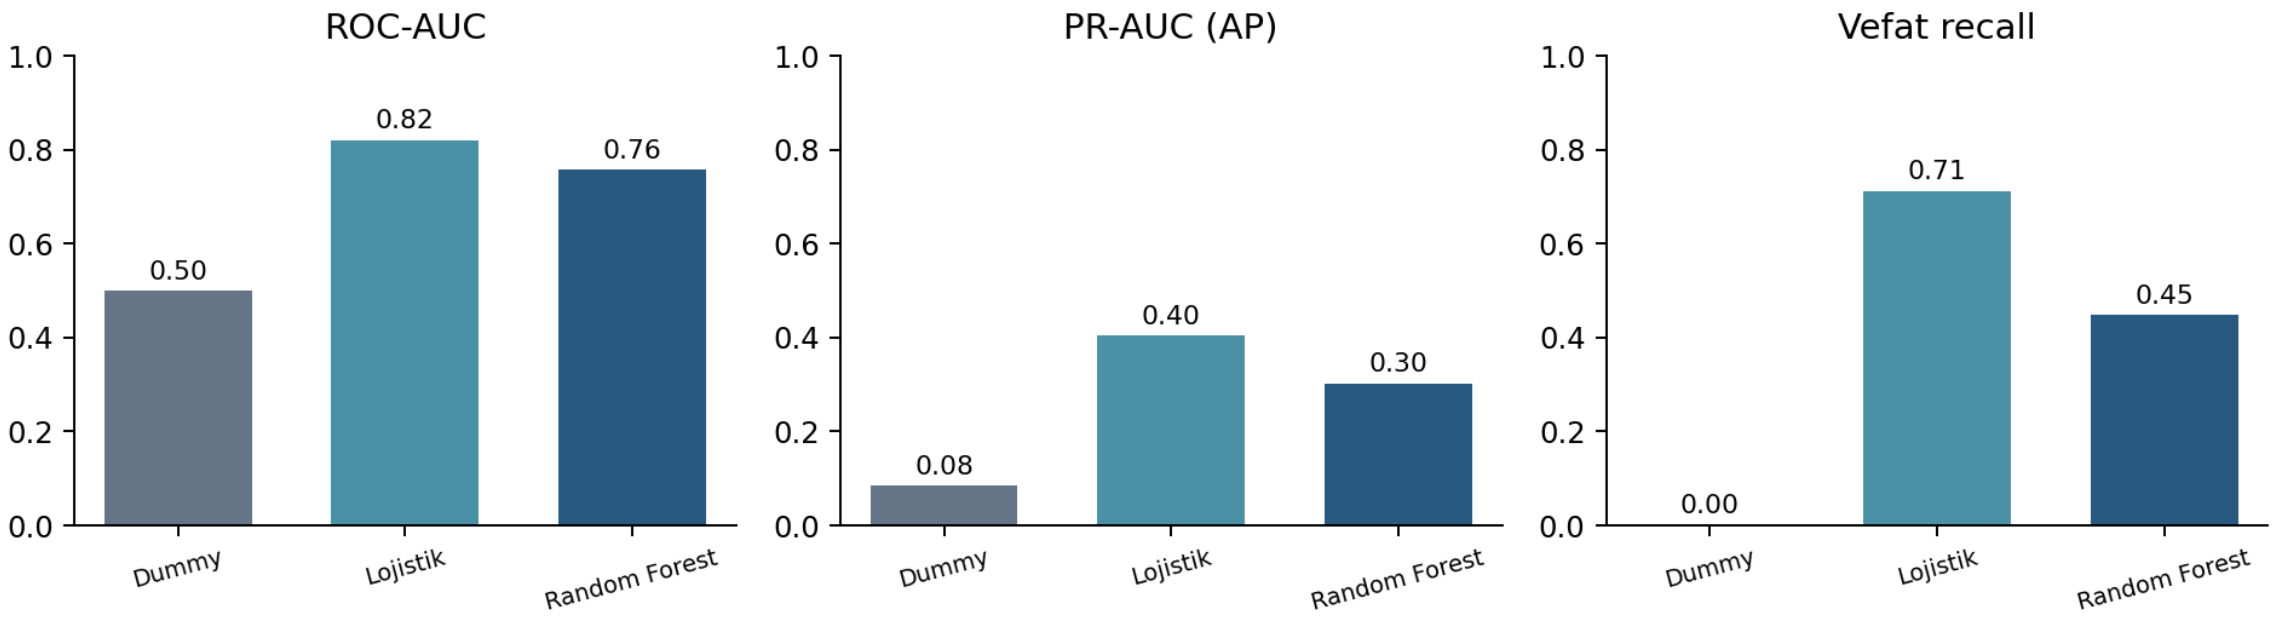
```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, stratify=y, random_state=42)
dummy = DummyClassifier(strategy="most_frequent")
```

DUMMY — TEST PERFORMANSI

Accuracy	ROC-AUC	PR-AUC	Recall (vefat)	Precision (vefat)	F1 (vefat)
0,918	**0,500**	**0,082**	**0,000**	**0,000**	**0,000**

Yüksek accuracy, vefat sınıfını yakalayamadığı için başarılı bir mortalite modeli anlamına gelmez.

Modeller: tekrarlı çapraz doğrulama



YALNIZCA EĞİTİM VERİSİNDE: 5 KAT × 5 TEKRAR = 25 DOĞRULAMA

```
cv = RepeatedStratifiedKFold(
    n_splits=5, n_repeats=5, random_state=42)
scores = cross_validate(model, X_train, y_train,
                        cv=cv, scoring=SCORING)
```

Lojistik regresyon CV ortalamasında ROC-AUC (0,8205), PR-AUC (0,4043) ve vefat recall (0,7117) bakımından öndedir.

Model seçimi ve güvenilirlik

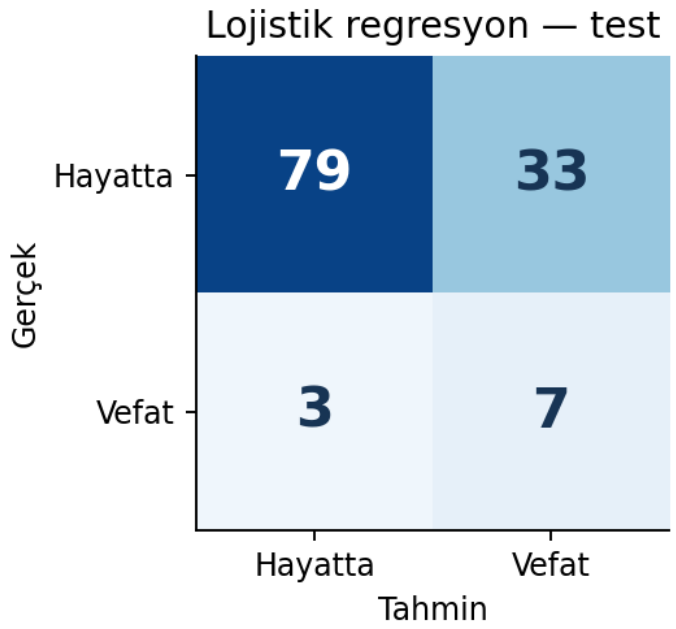
TEKRARLI CV SONUÇLARI

Model	ROC-AUC	PR-AUC	Recall (vefat)
Dummy	0.5000	0.0845	0.0000
Lojistik	**0.8205**	**0.4043**	**0.7117**
Random Forest	0.7574	0.3020	0.4483

NEDEN LOJİSTİK REGRESYON?

- Dengesiz veri için PR-AUC ve vefat recall özellikle önemlidir.
- Lojistik regresyon en yüksek ortalama değerleri verir ve yorumlanabilir.
- Katmanlar arasındaki değişkenlik yüksektir; üstünlük istatistiksel olarak kanıtlanmış değildir.

Test seti: lojistik regresyon



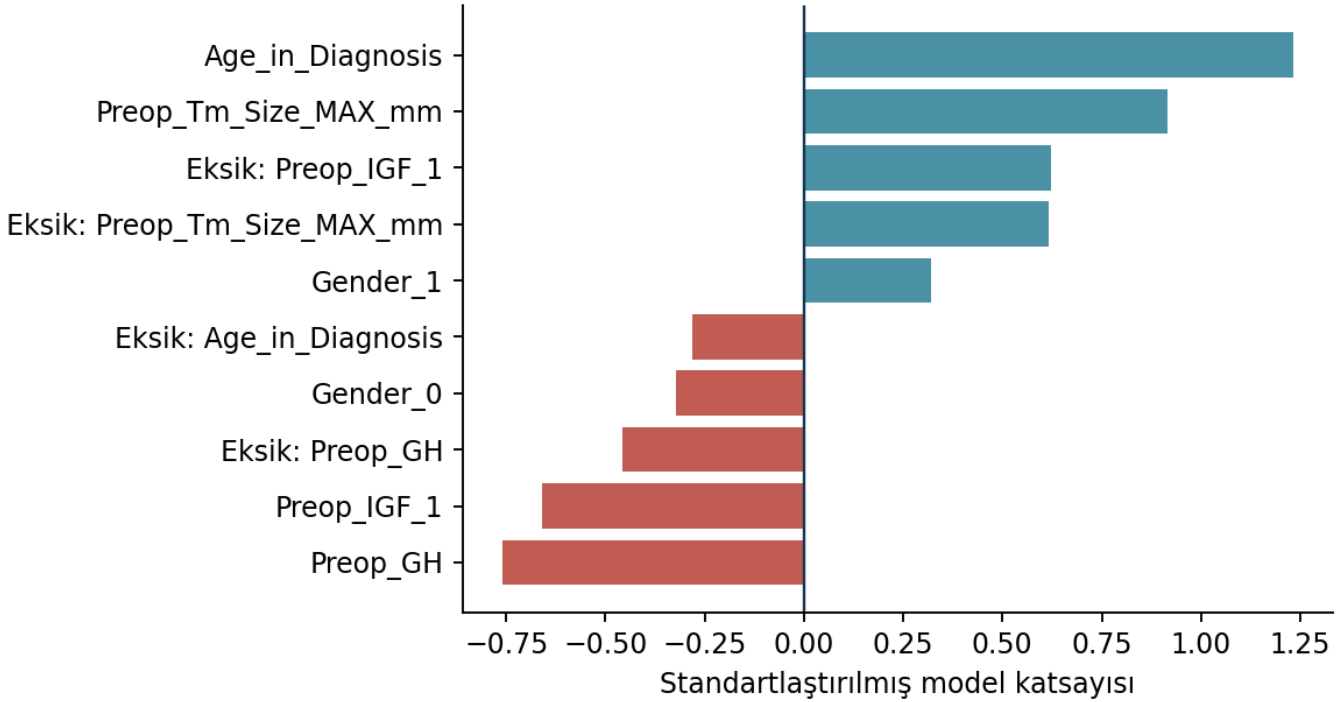
KİLİTLİ TEST SETİ — 122 HASTA

ROC-AUC	**0,8049**
PR-AUC (AP)	**0,3710**
Recall (vefat)	**0,70 (7/10)**
Precision (vefat)	**0,175 (7/40)**
F1 (vefat)	**0,2800**
Accuracy	**0,7049**

10 vefatın 7’si yakalandı; ancak hayatta olan 33 hasta yanlışlıkla vefat olarak tahmin edildi.

Test seti önceki analizlerde incelendiğinden bu değerler tamamen bağımsız bir son doğrulama olarak yorumlanmamalıdır.

Global önem ve yanlış pozitif örneği



YANLIŞ POZİTİF — KAYIT #240

- Gerçek durum: hayatta; tahmin: vefat.
- Tanı yaşı: 65; GH: 0,35; IGF-1: 255,9.
- Tümör boyutu bilgisi eksik.
- Model ölüm skoru: 0,977 (kalibre risk değildir).

Başlıca pozitif katkılar:

Yaş +2,61; tümör eksikliği +1,22.

Katsayılar modelin koşullu ilişkilerini gösterir; klinik nedensellik veya gerçek ölüm olasılığı olarak okunmamalıdır.

```
importance = model.named_steps["classifier"].coef_[0]
```

Sonuç ve yeniden çalıştırılabilirlik

SONUÇ

Tanı anında kullanılabileceği varsayılan beş değişkenle kurulan modeller arasında lojistik regresyon, çapraz doğrulamada en yüksek ROC-AUC (0,8205) ve PR-AUC (0,4043) ortalamalarını verdi. Tanı yaşı en belirgin pozitif katsayıya sahipken tümör boyutu ve eksiklik göstergeleri de model tahminine katkıda bulundu. Testte 10 vefatın 7'si yakalandı, fakat 33 yanlış pozitif oluştu. Yalnızca 51 vefat içeren veri, tekrar incelenmiş test seti ve doğrulanmamış ölçüm zamanları sonuçların güvenilirliğini sınırlar. Bu nedenle çalışma keşifsel niteliktedir; klinik kullanım için bağımsız dış doğrulama ve kalibrasyon gerekir.

YENİDEN ÜRETİLEBİLİR ANALİZ

```
python run_project.py --no-mlflow

# Veri: akromegali_alistirma.csv
 # Çıktılar: results/  (CV, test, grafikler, yorumlama)
```

Not: RF sonuçları scikit-learn sürümüne göre değişebildiği için bu sunumda kullanıcının Jupyter ortamında doğruladığı CV değerleri esas alınmıştır.